Segmentación de agua en imágenes de radar con SAM

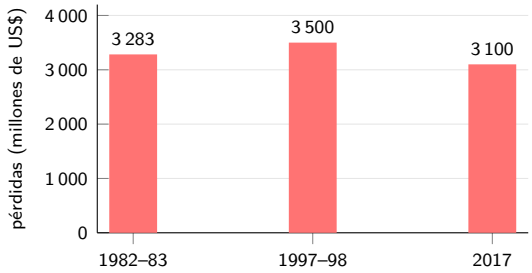
Qué probamos, qué funcionó y qué no

John Manuel Arzapalo Arana
Luis Alberto Miranda Mallqui
Juan Diego Zavala Viscardo

INF659 · Técnicas Avanzadas de Data Mining y Sistemas Inteligentes
Pontificia Universidad Católica del Perú

Presentación final · noviembre de 2026

Por qué importa: El Niño en el norte del Perú



11.6 %, 6.2 % y 1.6 % del PBI de cada época.

Niño Costero 2017

- **162** fallecidos y 1.13 millones de afectados.
- **25 700** viviendas colapsadas.

2026–27: ENFEN prevé un Niño costero de magnitud **extraordinaria**.

La necesidad

En la emergencia el cielo está nublado: hay que saber **dónde está el agua** con radar, que ve a través de las nubes, y sin que una persona dibuje cada mapa.

Fuentes: CAF/BCRP vía Andina (2023); OPS/OMS con SINPAD (2017); ENFEN, Comunicado Oficial N.º 19-2026.

La pregunta, los datos y cómo medimos

Pregunta

- ¿Sirve **SAM** (Meta, 2023), entrenado con 11 millones de fotos, para segmentar agua en **radar Sentinel-1**?
- Si no sirve tal cual, ¿qué hay que cambiar, y le gana a un modelo simple?

Datos: Sen1Floods11

- Recortes de 512×512 px (10 m), 11 inundaciones reales, máscaras dibujadas a mano.
- **train** 250 · **valid** 86 · **test** 89 · **Bolivia** 15 (región que ningún modelo vio).

Métrica

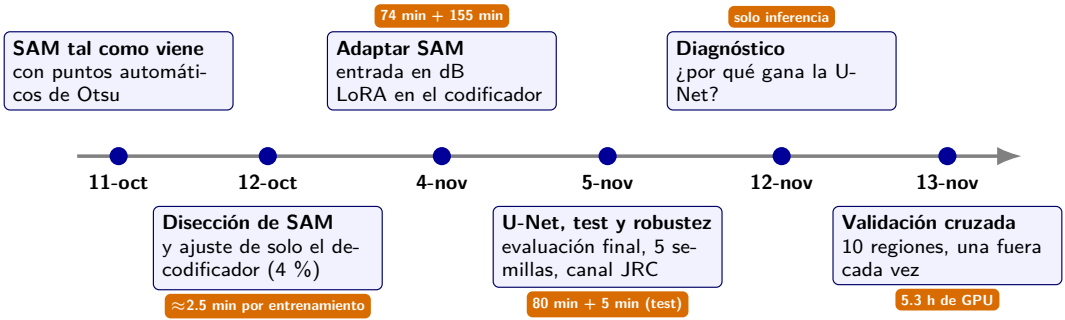
$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

IoU global: se suman los píxeles de todos los recortes. También se reporta el IoU medio por recorte.

Evaluación

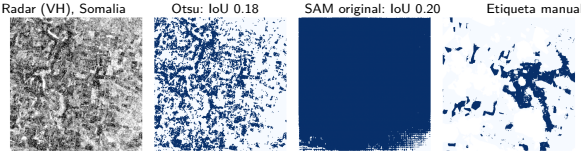
- Todas las decisiones se toman con train y valid.
- **test** y **Bolivia** se evalúan **una sola vez**, al final.
- Intervalos de confianza del 95 % con bootstrap (5 000 remuestreos).

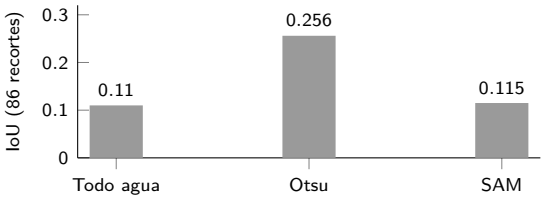
El recorrido en una línea de tiempo



Todo en una computadora con **RTX 3070 (8 GB)**. Los cuatro bloques grandes suman ≈**10.5 h de GPU**.

Capítulo 1: SAM tal como viene



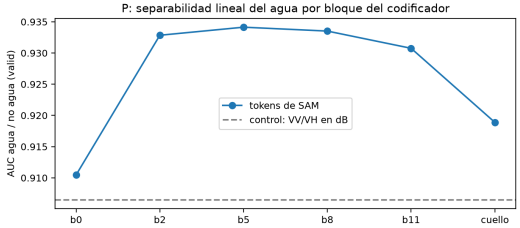


- **Método**: Otsu separa oscuro (agua) de claro y de ahí salen 3 puntos positivos y 2 negativos para SAM. Sin intervención humana.
- SAM **pinta casi toda la imagen** de agua: rinde igual que decir «todo es agua».
- Otsu gana en 69 de 86 recortes.

Resultado

SAM no supera a Otsu: 0.115 contra 0.256 (IC 95 % de la diferencia $[-0.18, -0.10]$).

¿Qué pieza falla? El «ojo» o el «pincel»



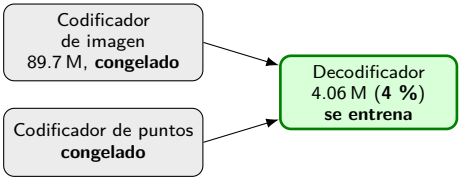
Sonda lineal por capa del codificador: AUC 0.934.

Sospecha	¿Es?
Los puntos: con puntos perfectos igual da 0.17	✗
El ojo (codificador): una recta separa agua y tierra (AUC 0.93)	✗
La confianza de SAM: $\rho = -0.05$ con el acierto real	✓
Elige la máscara más grande en 80 de 86	✓

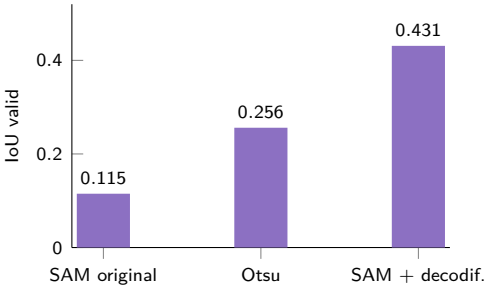
Conclusión

El codificador (96 % del modelo) **sí ve el agua**. Falla el decodificador: se autoevalúa mal y escoge la máscara equivocada.

Capítulo 2: reentrenar solo el decodificador (4 %)



- Las salidas del codificador se **guardan una vez**: después cada experimento cuesta minutos.
- Una sola máscara de salida: ya no depende de la confianza rota.
- ≈**2.5 min por entrenamiento** en GPU, 3 semillas.



Resultado

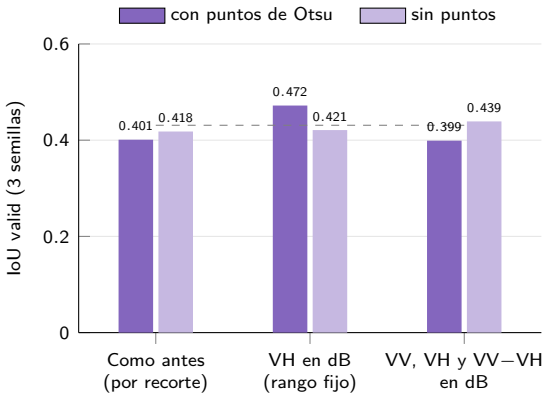
$0.115 \rightarrow \mathbf{0.431} \pm \mathbf{0.038}$: casi cuadruplica a SAM original y supera a Otsu en 57 de 86 recortes.

Capítulo 3: cómo seguir mejorando a SAM

Revisamos trabajos parecidos y nuestro código, y encontramos tres cosas que cambiar:

	Qué cambia	Por qué
1	Entrada con rango fijo en dB, con VV y VH	la normalización por recorte borraba el nivel absoluto del radar, que es lo que distingue el agua
2	LoRA en el codificador + rotaciones y espejados	el decodificador solo ya no daba más
3	Una U-Net desde cero, con la misma entrada	¿SAM aporta algo frente a una red simple?

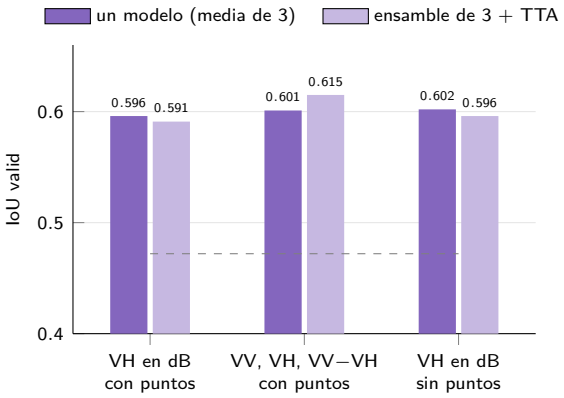
Entrada en dB: ayudó; elegir hiperparámetros en un subconjunto, no



Línea punteada: SAM + decodificador con la entrada anterior (0.431).

- Solo se entrena el decodificador; el codificador sigue congelado. 74 min en total.
- ✓ **VH en dB con rango fijo**: +0.071 con el mismo entrenamiento. Mejor resultado: **0.472** ± **0.017**.
- ✗ **Agregar VV y VV−VH**: −0.073 y muy inestable. Un codificador entrenado con fotos no entiende polarizaciones.
- ✗ **Elegir lr y época en un subconjunto de train** (51 recortes, 60 candidatos) sobrestimó valid entre 0.06 y 0.22: quedarse con el máximo de muchos candidatos engaña.

LoRA: adaptar el codificador de SAM



Línea punteada: solo el decodificador con entrada en dB (0.472).

- LoRA de rango 8 en las 12 capas de atención, más el decodificador: **4.35 M parámetros entrenables** (4.6 % de SAM).
- 9 entrenamientos de 15.6 min: 155 min en total. LoRA cupo en 4.3 GB de la GPU.
- ✓ Sube unos **+0.12** sobre el mejor resultado con el codificador congelado.
- ✓ Ahora VV y VV−VH sí ayudan: el codificador aprende a usarlos.
- El modelo elegido para test: **SAM + LoRA con VV, VH y VV−VH**, ensamble de 3 semillas + TTA (0.615).

La sorpresa: una U-Net simple gana en valid

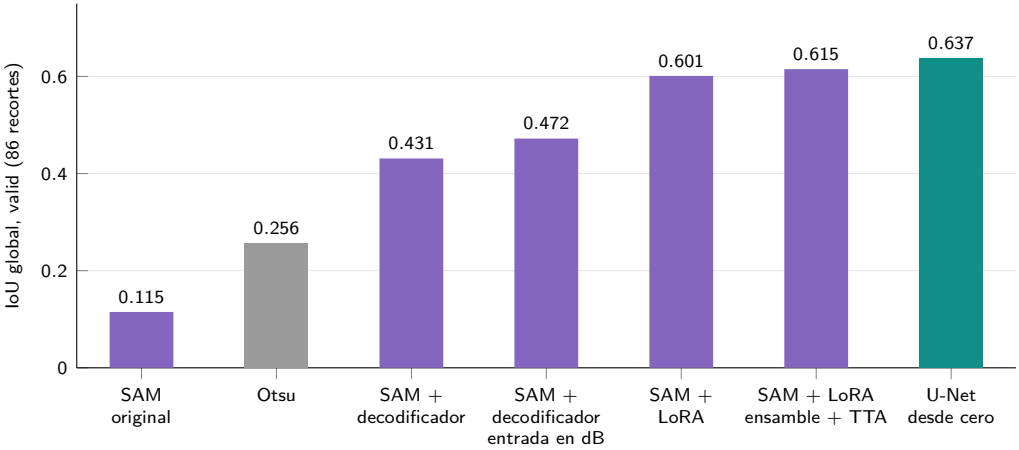
	SAM + LoRA	U-Net desde cero
Preentrenamiento	11 M de fotos	ninguno
Parámetros totales	93.7 M	7.76 M
Parámetros entrenados	4.35 M	7.76 M
Tiempo por semilla	15 min	10 min
IoU valid (media de 3)	0.601 ± 0.010	$\mathbf{0.637 \pm 0.003}$
Ensamble + TTA	0.615	**0.642**

- La U-Net gana en las 3 semillas (+0.027 a +0.042) y varía 3 veces menos.
- ✗ **Pérdida Tversky** en SAM (castigar más el agua perdida): 0.615, mejora no significativa.

Lo que cambia la historia

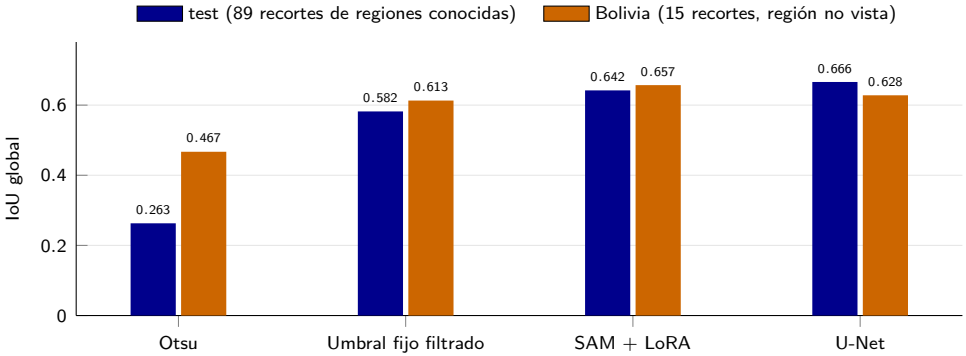
La entrada bien normalizada y las rotaciones bastan para que una red pequeña aprenda con solo 250 recortes.

Cómo subió el IoU en valid



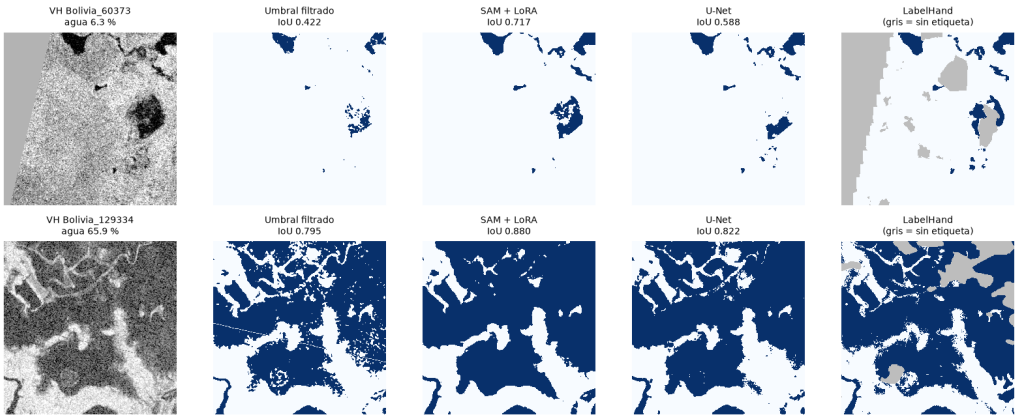
Morado: SAM · gris: método clásico · verde azulado: U-Net. Las barras de SAM con más de una semilla muestran la media de 3.

Capítulo 4: test y Bolivia, evaluados una sola vez



- Los modelos se fijaron antes de abrir test. Otsu y el umbral fijo son las referencias clásicas.
- SAM + LoRA: **0.642** en test y **0.657** en Bolivia, frente a 0.263 y 0.467 de Otsu.
- En test gana la U-Net (0.666). **En Bolivia, la región que nadie vio, gana SAM.**
- Con la métrica del paper del dataset (IoU medio por recorte), superamos su modelo con etiquetas manuales.

Bolivia: cómo se ven las predicciones



- Arriba: SAM recupera mejor la laguna de la derecha (0.72 contra 0.59 de la U-Net).
- Abajo, con 66 % de agua: los tres métodos aciertan lo grueso; el umbral deja ruido.
- Gris en la etiqueta: zonas sin etiquetar, que no cuentan.

Robustez: ¿se sostiene lo que vimos?

Una línea base clásica fuerte

- Umbral fijo en VH (-23.3 dB) con filtro de mediana, elegido solo en train.
- Test 0.582, Bolivia 0.613: **mucho mejor que Otsu**.
- En Bolivia la ventaja de los modelos sobre él ya no es concluyente.

Cinco semillas

- SAM 0.603 $\pm$ **0.017**; U-Net 0.635 $\pm$ **0.004**.
- SAM varía 4 veces más: por eso el ensamble le importa tanto.

IoU global contra IoU medio

- Test: 0.642 global, 0.405 medio.
- Un tercio de los recortes tiene <1 % de agua: pesan 3 % de los píxeles, pero un error pequeño los deja con IoU ≈ 0.
- Mapeamos bien el área inundada; fallamos más en imágenes casi secas.

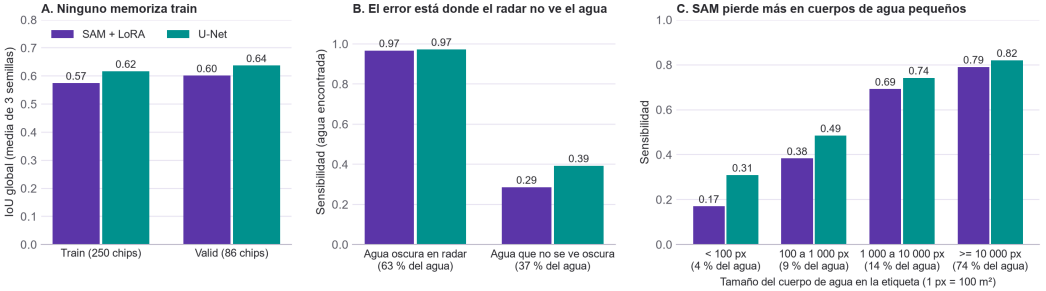
Agua permanente (JRC) como canal extra

- Valid $+0.010$, pero **Bolivia** -0.111: el modelo deja de marcar agua donde el mapa no la tenía.

Lo que no funcionó (y lo que nos enseñó)

Intento	Resultado	Lección
SAM con puntos automáticos	0.115	la confianza de SAM no sirve en radar
Más puntos o puntos perfectos	≤ 0.17	el problema no eran los puntos
VV + VH con el codificador congelado	-0.073	los canales nuevos piden adaptar el codificador
Elegir época y lr en un subconjunto de train	sobrestima 0.06–0.22	con pocos datos, quedarse con el máximo engaña
Pérdida Tversky	$+0.014$, no significativo	mover el equilibrio entre errores no basta
Canal de agua permanente (JRC)	Bolivia -0.111	una pista fácil daña la generalización
Promediar SAM y U-Net	$+0.001$	los dos fallan en los mismos píxeles

Capítulo 5: ¿por qué pierde SAM si tiene 12 veces más parámetros?



- **Nadie memoriza**: a SAM le falta ajuste, no le sobra.
- SAM entrena **menos** parámetros (4.35 M contra 7.76 M); el resto está congelado y aprendió con fotos.

- El límite lo pone **el radar**: los dos hallan el 97 % del agua oscura y fallan en el 37 % que no se ve oscura.
- SAM pierde más detalle fino: halla la mitad de los cuerpos de agua pequeños.

La literatura coincide: en Sen1Floods11 una U-Net desde cero queda primera dentro de las regiones de entrenamiento (PANGAEA 2024; Marti-Escofet et al. 2025).

Capítulo 6: validación cruzada dejando una región fuera

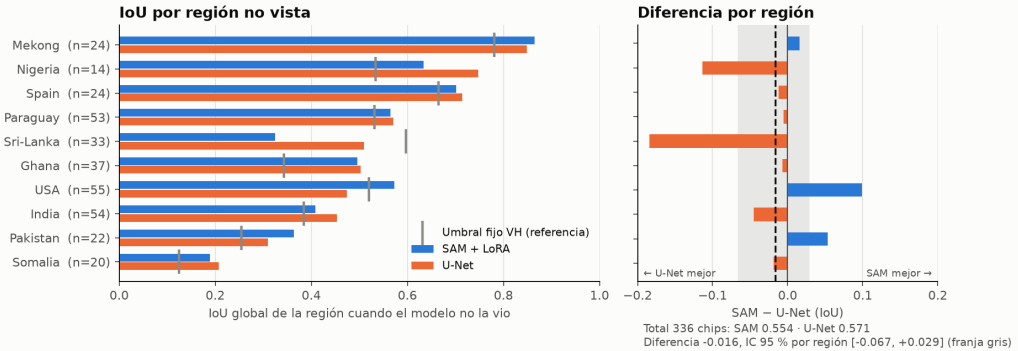


Cada fila es un pliegue. Azul: regiones con las que se entrena · naranja: la región que se predice sin haberla visto.

- **Pregunta**: ¿SAM generaliza mejor que la U-Net a regiones nuevas? Bolivia lo insinuaba, pero con 15 recortes.
- train + valid: **336 recortes**. Test y Bolivia no se tocan.
- Mismas recetas, semilla 0, sin búsqueda de hiperparámetros.
- Se declara un ganador solo si el IC 95 % por región excluye el cero.
- 10 pliegues de 28–46 min: **5.3 h de GPU**.

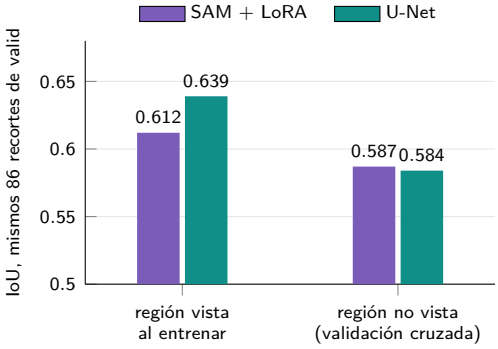
Resultado: en regiones nuevas, empate

Validación cruzada dejando una región fuera (train + valid, 10 regiones, semilla 0)



- SAM 0.554, U-Net 0.571: -0.017, IC $[-0.067, +0.029]$. **No hay diferencia significativa.**
- La U-Net gana en 7 regiones y SAM en 3.
- **La región pesa más que el modelo**: de 0.19 (Somalia) a 0.86 (Mekong).
- Los dos superan al umbral fijo en 8 o 9 de las 10 regiones.

Dónde sí destaca SAM: fuera de las regiones de entrenamiento



SAM cae 0.025; la U-Net, 0.055.

- **Bolivia**: SAM 0.657 contra 0.628, y gana en 10 de los 15 recortes.
- **Se degrada menos al cambiar de región**: la ventaja de la U-Net desaparece cuando la región es nueva (0.587 contra 0.584).
- **Menos falsas alarmas**: en las 10 regiones, precisión de 0.76 contra 0.71 de la U-Net, con 32 % menos píxeles marcados como agua sin serlo.
- Gana con claridad en **USA** (+0.098) y **Pakistan** (+0.053).

Lectura

El preentrenamiento de SAM le da **más estabilidad ante regiones no vistas** y un mapa más conservador. A cambio deja más agua sin marcar (sensibilidad 0.67 contra 0.75), y con 10 regiones la diferencia total no es significativa.

Cuánto costó cada etapa

Etapa	Tiempo	Qué se entrenó
SAM tal como viene, con puntos de Otsu	minutos	nada
Disección de SAM y ajuste del decodificador	≈2.5 min por modelo	decodificador, 3 semillas
Entrada en dB (solo decodificador)	74 min	6 configuraciones y 3 lr
LoRA en el codificador	155 min	9 modelos de 15.6 min
U-Net y pérdida Tversky	80 min	6 modelos
Evaluación en test y Bolivia	5 min	nada
Cinco semillas y canal JRC	—	7 modelos
Diagnóstico SAM contra U-Net	minutos	nada
Validación cruzada por región	5.3 h	20 modelos

Lo que lo hizo posible en una sola computadora

Guardar la salida del codificador de SAM (cada prueba del decodificador pasó de horas a minutos) y ahorrar memoria en el entrenamiento: SAM con LoRA cupo en 4.3 GB de una RTX 3070.

Conclusiones

1. **SAM tal como viene no sirve en radar**: no por los puntos ni por el codificador, sino porque su decodificador elige mal la máscara.
2. **Reentrenar solo el 4 % lo cuadruplica** ($0.115 \rightarrow 0.431$). Con la entrada en dB y LoRA llega a **0.642 en test** y **0.657 en Bolivia**.
3. **Una U-Net desde cero lo iguala o lo supera** dentro de las regiones de entrenamiento (0.666 en test). Más parámetros preentrenados no bastan.
4. **Fuera de esas regiones SAM se sostiene mejor**: gana en Bolivia, pierde menos al cambiar de región y da menos falsas alarmas. En 10 regiones nuevas, los dos empatan.
5. **El techo lo pone el sensor**: el agua que el radar no muestra oscura es casi todo el error de ambos modelos.

¡Gracias!

¿Preguntas?

Bonafilia et al. (2020) · Kirillov et al. (2023) · Hu et al. (2022, LoRA) · Ronneberger et al. (2015, U-Net) · Otsu (1979) · Garg et al. (2023) · Marsocci et al. (2024, PANGAEA) · Marti-Escofet et al. (2025) · ENFEN (2026) · OPS/OMS (2017)