Segmentación de agua en imágenes de radar con SAM

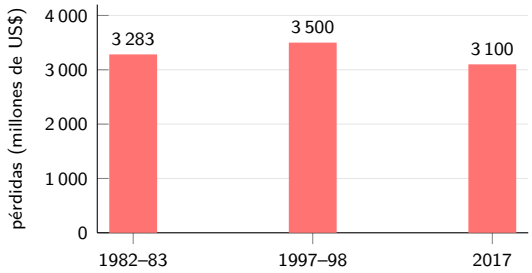
Qué probamos, qué funcionó y qué no

John Manuel Arzapalo Arana
Luis Alberto Miranda Mallqui
Juan Diego Zavala Viscardo

INF659 · Técnicas Avanzadas de Data Mining y Sistemas Inteligentes
Pontificia Universidad Católica del Perú

Presentación final · noviembre de 2026

Por qué importa: El Niño en el norte del Perú



11.6 %, 6.2 % y 1.6 % del PBI de cada época.

Niño Costero 2017

- **162** fallecidos y 1.13 millones de afectados.
- **25 700** viviendas colapsadas.
- El río Piura superó $3\,000\,m^3/s$ y se desbordó en la ciudad.

2026–27: ENFEN prevé un Niño costero de magnitud **extraordinaria**.

La necesidad

En la emergencia el cielo está nublado: hay que saber **dónde está el agua** con radar, que ve a través de las nubes, y sin que una persona dibuje cada mapa.

Fuentes: CAF/BCRP vía Andina (2023); OPS/OMS con SINPAD (2017); ENFEN, Comunicado Oficial N.º 19-2026.

La pregunta, los datos y la vara de medir

Pregunta

- ¿Sirve **SAM** (Meta, 2023), entrenado con 11 millones de fotos, para segmentar agua en **radar Sentinel-1**?
- Si no sirve tal cual, ¿qué hay que cambiar, y le gana a un modelo simple?

Datos: Sen1Floods11

- Recortes de 512×512 px (10 m), 11 inundaciones reales, máscaras dibujadas a mano.
- **train** 250 · **valid** 86 · **test** 89 · **Bolivia** 15 (región que nadie vio).

Métrica

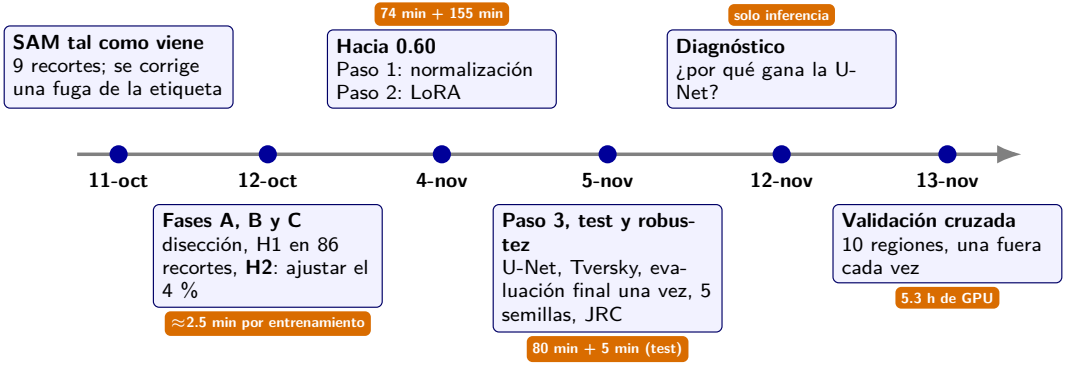
$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

IoU global: se suman los píxeles de todos los recortes. También se reporta el IoU medio por recorte.

Reglas que nos pusimos

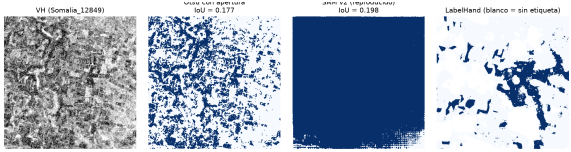
- **Pre-registro**: hipótesis, regla y expectativas escritas *antes* de correr.
- **test** y **Bolivia** se abren **una sola vez**.
- Intervalos 95 % con bootstrap (5 000).

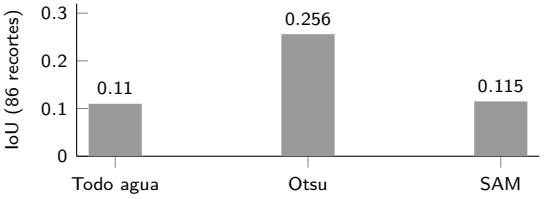
El recorrido en una línea de tiempo



Todo en una laptop con **RTX 3070 (8 GB)**. Los cuatro bloques grandes suman ≈**10.5 h de GPU**.

Capítulo 1: SAM tal como viene (H1)



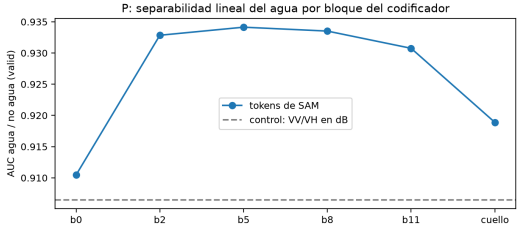


- **Método**: Otsu separa oscuro (agua) de claro y de ahí salen 3 puntos positivos y 2 negativos para SAM. Sin intervención humana.
- SAM **pinta casi toda la imagen** de agua: rinde igual que decir «todo es agua».
- Otsu gana en 69 de 86 recortes.
- En el camino hallamos una **fuga de la etiqueta** hacia los puntos y la corregimos (v2): el resultado no cambió.

H1: rechazada

0.115 contra 0.256 de Otsu (IC 95 % $[-0.18, -0.10]$).

¿Qué pieza falla? El «ojo» o el «pincel»



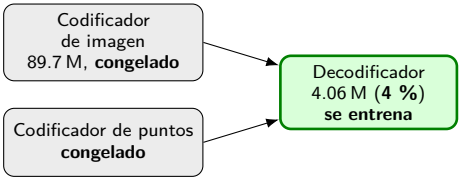
Sonda lineal por capa del codificador: AUC 0.934.

Sospecha	¿Es?
Los puntos: con puntos perfectos igual da 0.17	✗
El ojo (codificador): una recta separa agua y tierra (AUC 0.93)	✗
La confianza de SAM: $\rho = -0.05$ con el acierto real	✓
Elige la máscara más grande en 80 de 86	✓

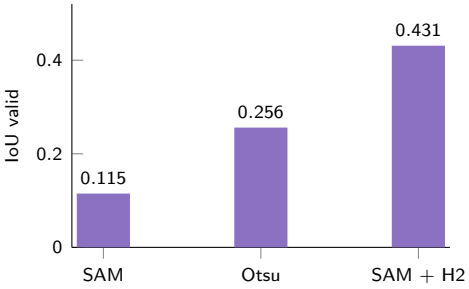
Conclusión

El codificador (96 % del modelo) **sí ve el agua**. Falla el decodificador: se autoevalúa mal y escoge la máscara equivocada.

Capítulo 2: reentrenar solo el 4 % (H2)



- Las salidas del codificador se **guardan una vez**: después cada experimento cuesta minutos.
- Una sola máscara de salida: ya no depende de la confianza rota.
- ≈**2.5 min por entrenamiento** en GPU, 3 semillas.



H2: confirmada

0.115 → **0.431** ± **0.038**: casi cuadruplica a SAM y supera a Otsu en 57 de 86 recortes.

Capítulo 3: la meta del profesor, IoU 0.60

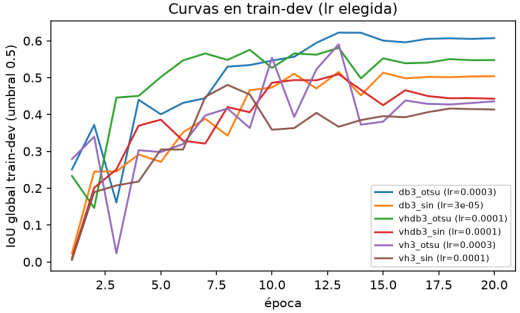
Partíamos de 0.431. Revisamos trabajos parecidos y el código, y armamos un plan por pasos:

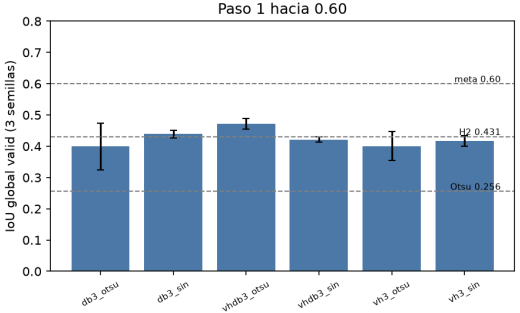
Paso	Qué cambia	Por qué	Tiempo
1	Rango fijo en dB, VV/VH, sin puntos	la normalización por recorte borraba el nivel del radar	74 min
2	LoRA en el codificador + rotaciones	el decodificador solo ya no daba más	155 min
3a	U-Net desde cero (línea base)	¿SAM aporta algo frente a una red simple?	80 min
3b	Pérdida Tversky	el error dominante es agua no detectada	
3c	Etiquetas débiles (4 385 recortes)	más datos	cancelado

Una regla en cada paso

Cada paso tuvo su pre-registro con hipótesis, regla de decisión y expectativas numéricas, escrito antes de lanzarlo y con la hora anotada en la bitácora.

Paso 1: normalizar en dB ayudó; elegir en train-dev, no

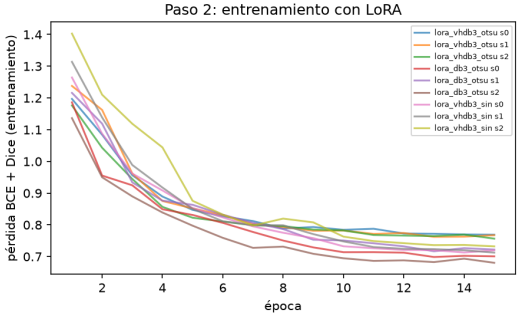


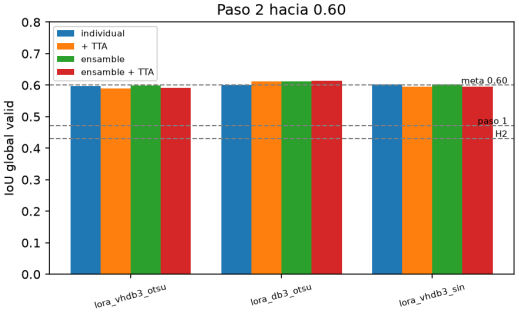


- ✓ **Rango fijo en dB**: $+0.071$ con el mismo entrenamiento. Mejor: 0.472 ± 0.017.
- ✗ **Agregar VV y VV$-$VH** con el codificador congelado: -0.073. Lo entrenado con fotos no entiende polarizaciones.

- ✗ **Elegir lr y época en train-dev** (51 recortes, 60 candidatos): sobrestimó valid entre 0.06 y 0.22. Es la **maldición del ganador**.
- La regla escogió `db3_otsu` (0.399): **H4 no se confirma**, y así se reportó.

Paso 2: LoRA cruza 0.60, por poco





- LoRA rango 8 en las 12 capas de atención + decodificador: **4.35 M entrenables** (4.6 %).
- Lección del paso 1: **ninguna selección**. Última época, umbral 0.5.
- 9 entrenamientos de 15.6 min cada uno.

- ✓ `lora_db3_otsu` **0.601** ± **0.010**; con ensamble + TTA, **0.615**.
- Ahora VV y VV−VH sí ayudan: el codificador aprende a usarlos.
- Margen mínimo: 4 de 9 semillas quedan bajo 0.60.

Paso 3: la sorpresa, una U-Net simple gana

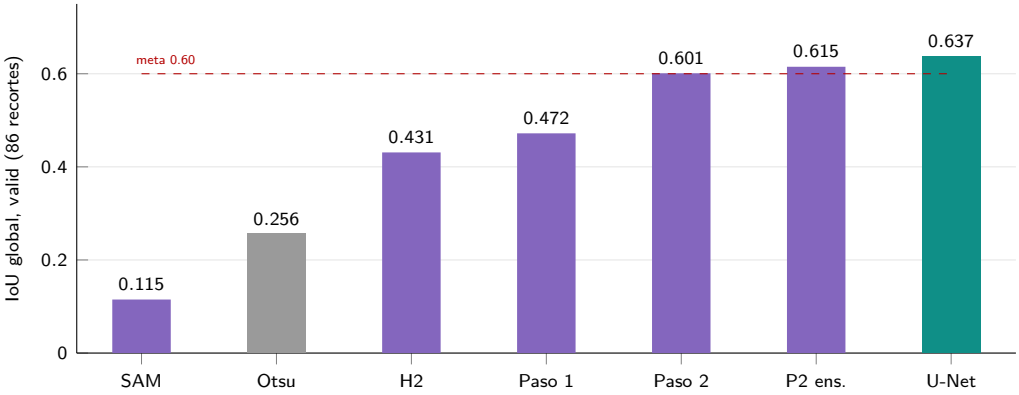
	SAM + LoRA	U-Net
Preentrenado	11 M fotos	nada
Parámetros totales	93.7 M	7.76 M
Parámetros entrenados	4.35 M	7.76 M
Tiempo por semilla	15 min	10 min
IoU valid	0.601 ± 0.010	$\mathbf{0.637 \pm 0.003}$
Ensamble + TTA	0.615	**0.642**

- La U-Net gana en las 3 semillas (+0.027 a +0.042) y es 3 veces más estable.
- Nuestra expectativa previa era 0.50–0.60 para la U-Net: **nos equivocamos**.
- ✗ **Tversky** (castigar más el agua perdida): 0.615, pero no cumple la regla de mejora.

Lo que cambia la historia

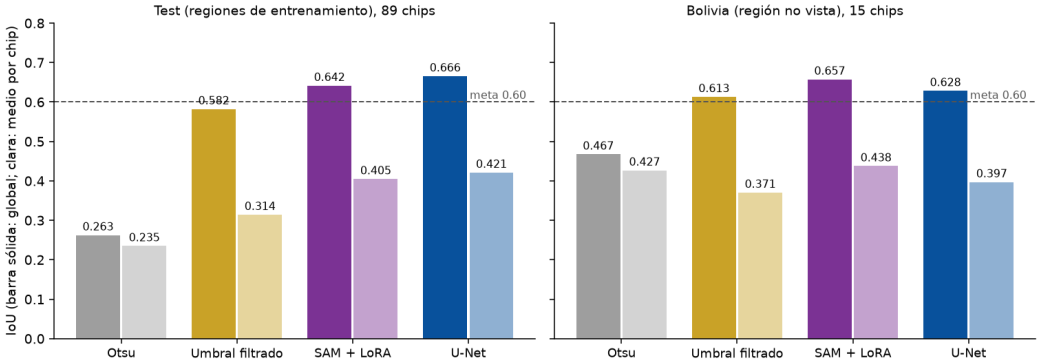
La entrada bien normalizada y las rotaciones bastan para que una red pequeña aprenda con solo 250 recortes.

Cómo subió el IoU en valid



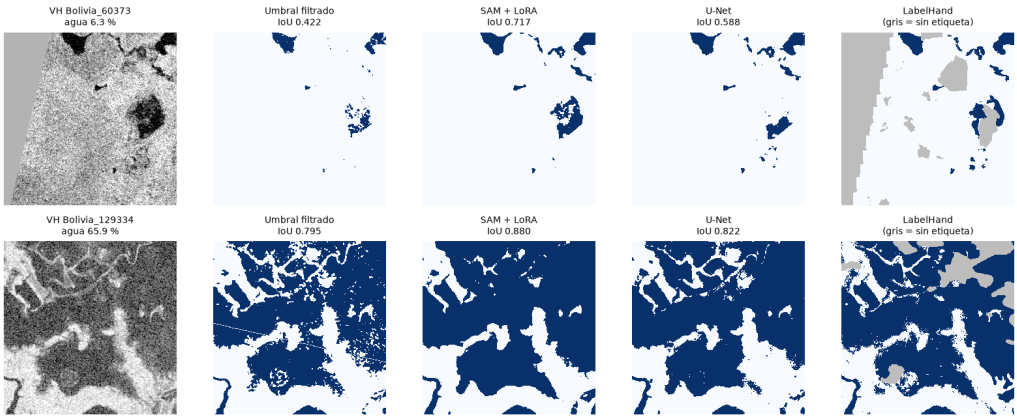
Morado: SAM · gris: Otsu · verde azulado: U-Net. «P2 ens.» = ensamble de 3 semillas + TTA, el candidato que fue a test.

Capítulo 4: test y Bolivia, una sola vez (5-nov)



- Candidato SAM fijado **antes** de abrir test. La U-Net entra como línea base.
- ✓ SAM cruza 0.60 en los dos: **0.642** y **0.657**.
- En test gana la U-Net (0.666); en Bolivia, la región no vista, gana SAM.
- Con la métrica del paper del dataset (IoU medio), superamos su modelo de etiquetas manuales.

Bolivia: cómo se ven las predicciones



- Arriba: SAM recupera mejor la laguna de la derecha (0.72 contra 0.59).
- Abajo, con 66 % de agua: los tres métodos aciertan lo grueso; el umbral deja ruido.
- Gris en la etiqueta: zonas sin etiquetar, que no cuentan.

Robustez: ¿se sostiene lo que vimos?

R1. Una línea base clásica honesta

- Umbral fijo en VH (-23.3 dB) con filtro de mediana, elegido solo en train.
- Test 0.582, Bolivia 0.613: **mucho mejor que Otsu**.
- En Bolivia la ventaja de los modelos sobre él ya no es concluyente.

R2. Cinco semillas

- SAM 0.603 $\pm$ **0.017**; U-Net 0.635 $\pm$ **0.004**.
- SAM varía 4 veces más: por eso el ensamble le importa tanto.

IoU global contra IoU medio

- Test: 0.642 global, 0.405 medio.
- Un tercio de los recortes tiene <1 % de agua: pesan 3 % de los píxeles, pero un error pequeño los deja con IoU ≈ 0.
- Mapeamos bien el área inundada; fallamos más en imágenes casi secas.

E1. Agua permanente (JRC) como canal

- Valid $+0.010$, pero **Bolivia** -0.111: el modelo deja de marcar agua donde el mapa no la tenía.

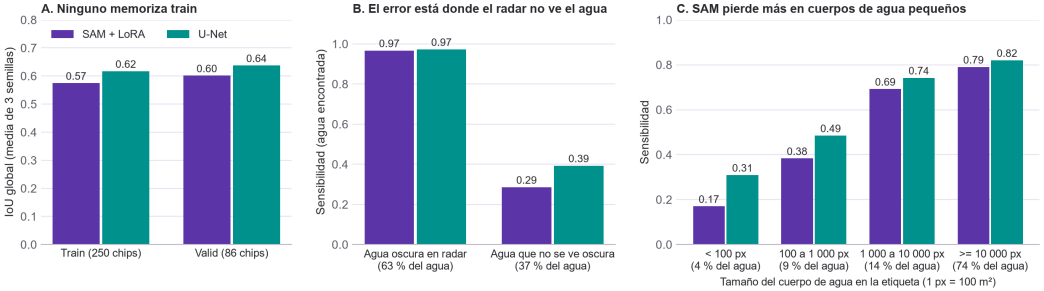
Lo que no funcionó (y lo que nos enseñó)

Intento	Resultado	Lección
SAM con puntos automáticos (H1)	0.115	la confianza de SAM no sirve en radar
Más puntos o puntos perfectos	≤ 0.17	el problema no eran los puntos
VV + VH con el codificador congelado	-0.073	los canales nuevos piden adaptar el codificador
Elegir época y lr en train-dev	sobrestima 0.06–0.22	con pocos datos, elegir el máximo engaña
Pérdida Tversky	$+0.014$, no significativo	mover el equilibrio FP/FN no basta
Canal de agua permanente (JRC)	Bolivia -0.111	una pista fácil daña la generalización
Etiquetas débiles	cancelado	demasiado costo para el tiempo disponible
Promediar SAM y U-Net	$+0.001$	los dos fallan en los mismos píxeles

Todo se reporta

Cada uno de estos resultados está en la bitácora con su pre-registro, aunque contradiga lo que esperábamos.

Capítulo 5: ¿por qué pierde SAM si tiene 12 veces más parámetros?

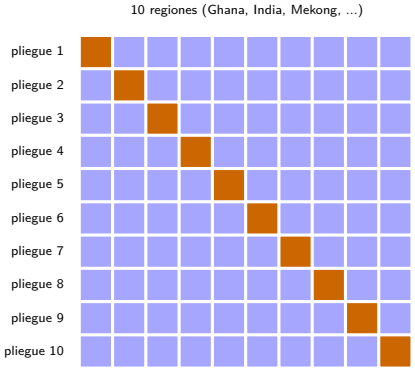


- **Nadie memoriza**: a SAM le falta ajuste, no le sobra.
- SAM entrena **menos** parámetros (4.35 M contra 7.76 M); el resto está congelado y aprendió con fotos.

- El límite lo pone **el radar**: los dos hallan el 97 % del agua oscura y fallan en el 37 % que no se ve oscura.
- SAM pierde más detalle fino: halla la mitad de los cuerpos de agua pequeños.

La literatura coincide: en Sen1Floods11 una U-Net desde cero queda primera dentro de las regiones de entrenamiento (PANGAEA 2024; Marti-Escofet et al. 2025).

Capítulo 6: validación cruzada dejando una región fuera

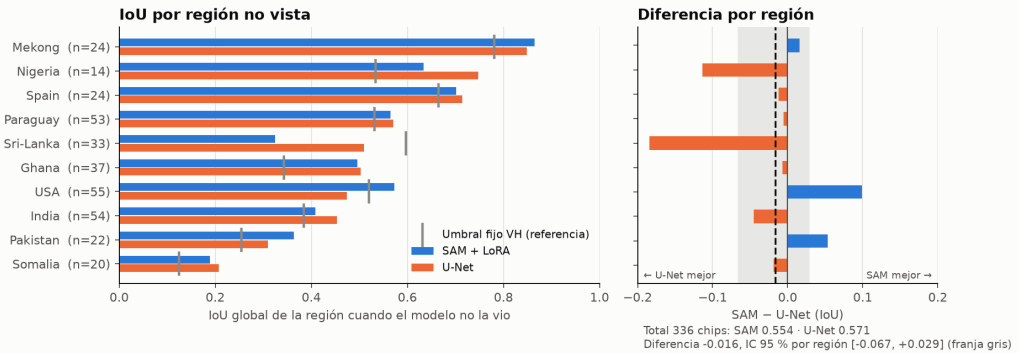


Azul: se entrena · naranja: se predice sin haberla visto.

- **Pregunta**: ¿SAM generaliza mejor que la U-Net a regiones nuevas? Bolivia lo insinuaba, pero con 15 recortes.
- train + valid: **336 recortes**. Test y Bolivia no se tocan.
- Mismas recetas, semilla 0, sin búsqueda de hiperparámetros.
- **Regla**: hay ganador solo si el IC 95 % por región excluye el cero.
- 10 pliegues de 28–46 min: **5.3 h de GPU**, corridas en 3 tramos.

Resultado: en regiones nuevas, empate

Validación cruzada dejando una región fuera (train + valid, 10 regiones, semilla 0)



- SAM 0.554, U-Net 0.571: -0.017, IC $[-0.067, +0.029]$. **Sin evidencia de diferencia.**
- La U-Net gana en 7 regiones y SAM en 3.
- **La región pesa más que el modelo**: de 0.19 (Somalia) a 0.86 (Mekong).
- Al cambiar de región SAM cae 0.025 y la U-Net 0.055: un indicio, no una prueba.

Cuánto costó cada etapa

Fecha	Etapa	Tiempo	Qué se entrenó
11-oct	SAM tal cual + corrección de la fuga	minutos	nada (9 recortes)
12-oct	Disección, H1 en 86 recortes, H2	≈2.5 min c/u	decodificador, 3 semillas
4-nov	Paso 1: normalización	74 min	6 configuraciones y 3 lr
4-nov	Paso 2: LoRA	155 min	9 modelos de 15.6 min
5-nov	Paso 3: U-Net y Tversky	80 min	6 modelos
5-nov	Test y Bolivia (una vez)	5 min	nada
5-nov	Robustez: 5 semillas y JRC	—	4 + 3 modelos
12-nov	Diagnóstico SAM contra U-Net	minutos	nada
12/13-nov	Validación cruzada por región	5.3 h	20 modelos

Dos decisiones que lo hicieron posible

Guardar la salida del codificador de SAM (cada prueba del decodificador pasó de horas a minutos) y usar la GPU de una laptop con trucos de memoria: LoRA cupo en 4.3 GB.

Conclusiones

1. **SAM tal como viene no sirve en radar**: no por los puntos ni por el codificador, sino porque su decodificador elige mal.
2. **Ajustar el 4 % lo cuadruplica** (0.115 $\rightarrow$ 0.431), y con LoRA y una entrada en dB **cruza 0.60**: 0.642 en test y 0.657 en Bolivia.
3. **Una U-Net desde cero lo iguala o lo supera** en las regiones de entrenamiento (0.666 en test). Más parámetros preentrenados no dan ventaja aquí.
4. **En regiones nuevas empatan**: 10 regiones no muestran diferencia; SAM pierde algo menos al cambiar de región.
5. **El techo lo pone el sensor**: el agua que el radar no ve oscura es casi todo el error de ambos.

Lo metodológico

Pre-registro, test abierto una sola vez y cada resultado negativo reportado: la respuesta es matizada, pero es defendible.

Qué haríamos después

- **Más semillas** en la validación cruzada: con una sola, la diferencia en una región puede ser ruido.
- **Detalle fino en el decodificador de SAM** (estilo HQ-SAM o Conv-LoRA) para los cuerpos de agua pequeños.
- **Subir el techo del sensor**: imagen óptica al entrenar o modelos preentrenados con radar.
- **Aplicarlo a Piura**: escenas del Niño 2017 y del Niño 2026–27, restando el agua permanente con una imagen previa.

Lo que no afirmamos

Nada de esto se ha probado todavía en Piura: falta evaluarlo allí.

¡Gracias!

¿Preguntas?

Bonafilia et al. (2020) · Kirillov et al. (2023) · Hu et al. (2022, LoRA) · Ronneberger et al. (2015, U-Net) · Otsu (1979) · Garg et al. (2023) · Marsocci et al. (2024, PANGAEA) · Marti-Escofet et al. (2025) · ENFEN (2026) · OPS/OMS (2017)